

LAPORAN PROYEK ADAPTASI

Pipeline Data, Machine Learning, LLM Grounding, dan Dashboard

Item	Keterangan
Mata kuliah	Teknologi Cerdas
Track	Adapt
Lokasi proyek	proyek_adaptasi/
Penyusun	Belum diisi
Tanggal laporan	21 September 2026

Status dokumen: rancangan implementasi

Laporan ini dibuat berdasarkan pemeriksaan kode pada repository. Dataset mentah, konfigurasi dataset, dan artefak pelatihan belum tersedia; karena itu tidak ada angka performa atau klaim hasil eksperimen yang dicantumkan.

1. Ringkasan Eksekutif

Proyek ini menyediakan kerangka kerja aplikasi teknologi cerdas untuk masalah klasifikasi yang akan diadaptasi ke dataset baru. Alurnya mencakup validasi data, pembersihan dan pemisahan data, pelatihan baseline serta Random Forest, evaluasi model, penyimpanan artefak, dashboard Streamlit, dan analisis bahasa alami berbasis LLM lokal melalui Ollama.

Pada kondisi repository saat laporan ini dibuat, nama dataset, target, fitur, stakeholder, metrik utama, dan konteks aplikasi masih belum ditentukan. Dengan demikian, artefak ini berfungsi sebagai laporan desain dan checklist implementasi; bagian hasil wajib diperbarui setelah kontrak data diisi dan eksperimen dijalankan.

2. Ruang Lingkup dan Tujuan

Komponen	Peran dalam sistem
Data	CSV lokal pada data/raw/; diperiksa terhadap kontrak konfigurasi.
Data preparation	Memilih kolom, menghapus duplikat, menghapus target kosong, dan menghasilkan split train/test.
Machine learning	Membandingkan DummyClassifier (baseline) dengan RandomForestClassifier.
LLM	Menyusun prompt grounded dari record, prediksi, dan metrik; pemanggilan Ollama bersifat opsional.
Aplikasi	Dashboard Streamlit untuk data, BI, prediksi per baris, dan analisis grounded.

3. Arsitektur Sistem

Arsitektur yang diimplementasikan di kode adalah sebagai berikut.

```
CSV mentah -> validasi konfigurasi -> cleaning dan split -> pipeline preprocessing + model -> artefak model/metrics/prediksi -> dashboard Streamlit. Pada dashboard, record dan output ML menjadi evidence untuk prompt LLM -> Ollama -> analisis untuk pengguna.
```

Pemisahan preprocessing dan model dilakukan memakai sklearn Pipeline sehingga imputer dan encoder dipelajari dari data latih. Pendekatan ini membantu menghindari kebocoran informasi dari test set saat pelatihan.

4. Data dan Persiapan

Kontrak data berada pada config.py. Konfigurasi saat ini masih berisi placeholder: DATA_FILENAME dan TARGET belum diisi, daftar fitur numerik/kategorikal kosong, dan TASK ditetapkan sebagai classification. Fungsi validate_config() menghentikan proses lebih awal apabila placeholder tersebut belum diganti.

Tahap	Implementasi saat ini	Catatan adaptasi
Validasi	Memastikan file, kolom wajib, data tidak kosong, dan minimal dua kelas target.	Isi data dictionary dan semantik semua fitur.
Cleaning	Memilih fitur/target/ID, menghapus baris duplikat dan target kosong.	Tambahkan aturan nilai tidak valid/outlier sesuai domain.

Tahap	Implementasi saat ini	Catatan adaptasi
Split	train_test_split 80/20, random_state=42, stratified pada target.	Ganti menjadi group/time split bila observasi tidak independen.
Kualitas	Menyimpan data_quality.json: jumlah baris, duplikat, distribusi target, dan missing value.	Interpretasikan laporan kualitas setelah dataset tersedia.

5. Metode Machine Learning

Fitur numerik diimputasi menggunakan median. Fitur kategorikal diimputasi menggunakan nilai paling sering lalu di-one-hot encoding dengan `handle_unknown='ignore'`. Baseline memakai `DummyClassifier(strategy='most_frequent')`. Model utama memakai `RandomForestClassifier` dengan 300 trees, `class_weight='balanced'`, `random_state=42`, dan `n_jobs=-1`.

Evaluasi yang telah disediakan adalah accuracy, macro F1, confusion matrix, dan classification report per kelas. Metrik utama belum ditetapkan; pemilihannya harus mengikuti biaya kesalahan stakeholder. Contohnya, recall relevan bila false negative mahal, sedangkan precision relevan bila tindak lanjut positif mahal.

6. Aplikasi dan Integrasi LLM

Aplikasi Streamlit memverifikasi keberadaan dataset dan artefak sebelum menampilkan empat tab: Data, BI, ML, dan LLM. Tab Data menampilkan preview serta missing value. Tab ML menjalankan prediksi pada satu baris. Tab BI dan judul aplikasi masih placeholder sehingga perlu dirancang ulang agar sesuai pertanyaan stakeholder.

Prompt LLM mengirimkan JSON yang berisi record fitur, prediksi model, dan evaluasi model. Instruksi prompt membatasi model agar menggunakan evidence yang diberikan, membedakan bukti/inferensi/rekomendasi, menyatakan kekurangan bukti, dan membatasi rekomendasi hingga tiga tindakan. Ini adalah mekanisme grounding, tetapi tetap perlu diuji terhadap kasus nyata untuk mendeteksi klaim yang tidak didukung.

7. Hasil dan Status Verifikasi

Artefak yang diharapkan	Status saat diperiksa	Implikasi
data/raw/.csv	Belum ada (hanya .gitkeep)	Profil data belum dapat dibuat.
data/processed/train.csv dan test.csv	Belum ada	Pipeline persiapan belum dijalankan.
artifacts/model.joblib	Belum ada	Prediksi dashboard belum dapat digunakan.
artifacts/metrics.json	Belum ada	Tidak ada metrik yang sah untuk dilaporkan.
artifacts/predictions.csv	Belum ada	Analisis error belum dapat dilakukan.

Kesimpulan performa belum dapat dibuat. Tabel eksperimen, confusion matrix, threshold analysis, dan evaluasi LLM harus diisi hanya dari artifacts yang dihasilkan pada run yang dapat direproduksi.

8. Reprodusibilitas

Setelah kontrak data lengkap, jalankan perintah berikut dari folder proyek_adaptasi.

```
python -m pip install -r requirements.txt
python data_prep.py
python train.py
python llm.py --prompt-only
streamlit run app.py
```

Dependensi proyek merujuk requirements tingkat repository dan requirements simulation. Untuk reproduksibilitas yang lebih kuat, dokumentasikan versi Python, versi paket aktual, checksum dataset, tanggal akses data, seed, serta model Ollama yang digunakan.

9. Risiko, Etika, dan Keterbatasan

Karena dataset belum ditentukan, risiko privasi, fairness, representativitas, dan lisensi belum dapat dinilai secara spesifik. Sebelum deployment, Data Card perlu menjelaskan sumber/izin, unit observasi, periode/wilayah, potensi bias sampling dan measurement, kolom sensitif, serta batas penggunaan. Keputusan penting tidak boleh diotomatisasi sepenuhnya; pengguna perlu dapat meninjau evidence, prediksi, dan keterbatasannya.

Keterbatasan teknis saat ini: scaffold hanya mendukung classification, split masih acak, model tidak menyimpan probabilitas/threshold analysis, dan UX/BI belum disesuaikan ke domain. LLM dapat tetap menghasilkan penjelasan yang tampak meyakinkan, sehingga evaluasi konsistensi evidence dan human override diperlukan.

10. Kesimpulan dan Tindak Lanjut

Repository telah menyediakan fondasi end-to-end yang baik untuk proyek klasifikasi adaptif: pemisahan data, preprocessing dalam pipeline, baseline, model utama, dashboard, dan prompt grounded. Namun proyek belum dapat dinilai sebagai implementasi substansif karena konfigurasi dan data belum diisi serta eksperimen belum dijalankan.

Prioritas selanjutnya adalah: (1) memilih dataset berizin dan melengkapi Data Card; (2) mengisi config.py berdasarkan semantik data; (3) menyesuaikan cleaning, split, metrik, BI, dan prompt; (4) menjalankan eksperimen; dan (5) mengganti bagian status pada laporan ini dengan hasil terukur.

Lampiran: Berkas yang Ditinjau

app.py, config.py, data_prep.py, train.py, llm.py, README.md, DATA_CARD.md, requirements.txt, serta struktur folder data/ dan artifacts/.