STUDENT DROPOUT ANALYSIS

Ringkasan dataset

Cakupan, struktur kolom, dan makna target

1. Pertanyaan dan isi dataset

Ringkasan dimulai dari pertanyaan: ?Apa isi dataset._StudentDOA.csv yang ada di folder StudentDoa?? File yang tersedia bernama dataset_StudentDOA.csv (tanpa titik setelah kata dataset), berada di folder StudentDOA, dan memakai tanda titik koma sebagai pemisah kolom.

4.424	35	3	0
baris mahasiswa	kolom	kelas target	sel kosong terdeteksi

2. Kelompok informasi dalam 35 kolom

- Pendaftaran dan pendidikan sebelumnya: status perkawinan, mode dan urutan aplikasi, program studi (Course), jadwal kuliah, kualifikasi sebelumnya, serta kewarganegaraan.
- Latar belakang keluarga: kualifikasi pendidikan dan pekerjaan ibu serta ayah.
- Kondisi mahasiswa: status perpindahan tempat tinggal, kebutuhan pendidikan khusus, utang, pembayaran biaya kuliah, gender, beasiswa, usia saat masuk, dan status internasional.
- Akademik: jumlah mata kuliah dikreditkan, diambil, dievaluasi, lulus, nilai, dan tanpa evaluasi pada semester pertama dan kedua.
- Konteks ekonomi: tingkat pengangguran, inflasi, dan GDP.

3. Distribusi status akhir (Target)

Status	Jumlah mahasisw	Persentase
Graduate	2.209	49,9%
Dropout	1.421	32,1%
Enrolled	794	17,9%

Setiap baris mewakili seorang mahasiswa. Target memungkinkan klasifikasi tiga kelas: lulus, berhenti, atau masih terdaftar.

Alur analisis dan aplikasi

Tiga skrip dibuat di dalam folder StudentDOA

4. Tahap pengolahan yang ditampilkan di web

01 Data Kaggle
Membaca dataset_StudentDOA.csv dengan pemisah titik koma.

02 Pemeriksaan
Memastikan kolom fitur dan Target tersedia; meringkas baris, kolom, distribusi target, serta nilai kosong.

03 Pembersihan
Mengubah format angka grade yang memiliki banyak titik menjadi angka desimal. Kode kategori diproses sebagai kategori.

04 Pemodelan
Membagi data secara stratified: 80% latih dan 20% uji; melatih Random Forest.

05 Interpretasi
Menampilkan metrik evaluasi, confusion matrix, kepentingan fitur, dan contoh prediksi historis.

5. File yang dibuat dan fungsinya

- Data_Prev.py: membaca dan memvalidasi dataset, membersihkan grade, membuat pembagian data, lalu menghasilkan student_clean.csv, student_train.csv, student_test.csv, dan data_summary.json.
- Ml_model.py: melatih model Random Forest dari data latih, mengevaluasinya pada data uji, dan menyimpan pipeline model, metrik, feature importance, serta prediksi uji.
- App.py: dashboard Streamlit dengan tab Ringkasan, Filter & jelajahi data, serta Machine Learning. Filter mencakup status akhir, rentang usia, kode Course, utang, dan beasiswa; hasil filter dapat diunduh sebagai CSV.

Catatan metodologi

Fitur model menggunakan informasi pendaftaran dan semester pertama. Kolom semester kedua tidak digunakan sebagai fitur agar model tidak memakai informasi yang muncul setelah periode prediksi. Hasil prediksi ditujukan untuk pembelajaran, bukan keputusan otomatis tentang mahasiswa.

Hasil dan cara menjalankan

Rekap eksekusi yang dilaporkan di terminal

6. Hasil pelatihan model

Pembagian data yang berhasil dibuat: 3.539 baris data latih dan 885 baris data uji. Model Random Forest selesai dilatih dan menghasilkan metrik berikut:

0,713
Accuracy

0,666
Macro F1

Accuracy 0,713 berarti sekitar 71,3% prediksi pada data uji cocok dengan label aktual. Macro F1 0,666 merangkum precision dan recall untuk setiap kelas dengan bobot setara. Kedua angka ini adalah hasil evaluasi pada pembagian data yang digunakan, bukan jaminan kinerja pada data baru.

7. Perintah menjalankan dari folder StudentDOA

python Data_Prev.py

python Ml_model.py

streamlit run App.py

Urutan eksekusi yang dilaporkan berhasil: Data_Prev.py membuat file persiapan data; Ml_model.py selesai melatih model dan menyimpan artefaknya; kemudian dashboard dijalankan dengan Streamlit dan pengguna mengonfirmasi bahwa aplikasi dapat dibuka.

8. Artefak model

student_status_pipeline.pkl ? feature_importance.csv ? model_metrics.json ? student_predictions.csv

Aplikasi memperlihatkan evaluasi, confusion matrix, fitur penting, dan peluang kelas untuk satu rekaman historis yang dipilih. Dataset sumber tetap menjadi dataset StudentDOA.